Hungarian Housing Intelligence

Szoftver- és Data Engineering esettanulmány | 2024. július – 2026. november

A projekt áttekintése

A 2024 júliusában, Debrecen lakásárait követő Python web scraperként indult fejlesztés fokozatosan **47 magyarországi lokációt lefedő, felhőalapú adatgyűjtő és elemzőplatformmá** fejlődött.

A projekt megközelítőleg két és fél évre visszanyúló historikus adatokat kapcsol össze automatizált adatgyűjtéssel, adatbázis-kezeléssel, statisztikai elemzéssel és interaktív webes dashboarddal. A leghosszabb idősor Debrecenhez tartozik; a 47 lokációs bővítés később indult.

A technikai fejlődés fő állomásai

- **1. Adatgyűjtés és feldolgozás (2024).** Python scraper fejlesztése Requests és BeautifulSoup használatával; ingatlanhirdetések adatainak kinyerése, négyzetméterárak számítása és historikus lakásárindex kialakítása az 50–60 m²-es lakásokra fókuszálva.
- **2. Felhős automatizálás és adattárolás (2024–2025).** Az AWS Lambda és DynamoDB integrálásával az adatgyűjtés automatizálása és a hosszú távú tárolás megoldása. MySQL integrálása a strukturált adatkezeléshez és idősoros elemzéshez.
- **3. Bővítés 47 lokációra (2026).** A debreceni rendszer országos kiterjesztése 47 földrajzi lokációra, köztük Budapest mind a 23 kerületére. Az adatfeldolgozó folyamat újratervezése lokációalapú indexeléssel, UUIDv7-azonosítókkal, kötegelt adatbázis-műveletekkel és duplikációvédelemmel.
- **4. Elemzés és desktopalkalmazás (2025–2026).** CustomTkinter, Pandas és Matplotlib alapú asztali alkalmazás készítése adatexporttal, historikus grafikonokkal és technikai indikátorokkal: mozgóátlagok, Bollinger-szalagok, RSI és MACD.
- **5. Interaktív webes dashboard (2026. november).** Streamlit- és Plotly-alapú dashboard fejlesztése és publikálása városszűréssel, idősorelemzéssel, lokációs rangsorokkal és letölthető adatkészletekkel.

Rendszerarchitektúra

- **Adatgyűjtés:** Python · Requests · BeautifulSoup · AWS Lambda
- **Tárolás és feldolgozás:** DynamoDB · MySQL · Pandas · SQL
- **Elemzés és vizualizáció:** CustomTkinter · Matplotlib · Plotly · Streamlit · Power BI
- **Publikálás és verziókezelés:** Git · GitHub · Streamlit Community Cloud

Fő mérnöki kihívások

- A scraper működőképességének fenntartása a forrásweboldal HTML-struktúrájának változásai ellenére.
- Az automatizált adatgyűjtés skálázása egyetlen városról 47 lokációra.
- A korábbi historikus adatok integrálása az új, többlokációs adatbázis-modellbe.
- Adatkonzisztencia, duplikációk megelőzése, valamint a felhős és a helyi adatbázis szinkronizálása.
- Az adatgyűjtési, tárolási, feldolgozási és megjelenítési rétegek elkülönítése a jobb karbantarthatóság érdekében.

Eredmények és továbbfejlesztési irányok

Az eredmény egy végponttól végpontig felépített data engineering projekt, amely gyakorlati tapasztalatot mutat be a **Python-fejlesztés, felhős automatizálás, adatbázis-tervezés, ETL-folyamatok, adatelemzés és interaktív webalkalmazás-fejlesztés** területén.

A platform tovább fejlődik: a tervezett irányok között összetettebb piaci összehasonlítások, fejlettebb statisztikai elemzés, automatizált webes adatfrissítés és új vizualizációs funkciók szerepelnek.

Projektlinkek

- **Élő dashboard:** https://hungarian-housing-intelligence.streamlit.app
- **GitHub:** https://github.com/GregTakacsGergo/hungarian-housing-intelligence